



박찬희

고려대학교 컴퓨터학과 석사과정 NLP&AI 연구실 (지도 교수 : 임희석)

연구 주제 : 벤치마크 설계, 에이전트 개발·평가, 도메인 전이, 추론 효율화

연구 성과 : 1저자 논문 4편 (게재 3건, arXiv 1건), 국내 특허 출원 2건

프로젝트 경력 : 산학 프로젝트 4건, AI SaaS 개발 테크 리드

“언어 모델의 **신뢰성 (Reliability)**을 측정하고, 실제 현장에 **접목하는 (Application)** 연구를 수행합니다.”



pch7678@korea.ac.kr



[Google Scholar](#)



[Website](#)



[github](#)



[LinkedIn](#)



Natural Language
Processing
& Artificial Intelligence



고려대학교
KOREA UNIVERSITY

약력

Education

2014.02. 한영외국어고등학교 졸업
2020.02. 고려대학교 국어국문학과 졸업
2027.02. 고려대학교 컴퓨터학과 졸업 예정

Projects

- **유방암 의료 결정 지원용 RAG 시스템 개발** **구로병원** **2024**
1,356개 현행 ASCO 가이드라인 문서 수집 및 RAG 파이프라인 구축
- **독자 파운데이션 모델 개발** **NC AI** **2025**
4개 언어, 9개 도메인에 달하는 6.5M Q&A SFT 데이터 샘플 수집 및 정제
- **LegalMi:dm 법률 특화 버티컬 모델 개발** **KT** **2025**
Midm-2.0-Base (11.5B) 모델의 법률 특화 continual pre-training 담당
- **국어생활종합상담 멀티 에이전트 개발** **문체부** **2026**
KTC 공인인증 위한 평가 및 메트릭 개발

Career

2020.03~2023.06 공군 영어 통역장교
2023.06~2023.10 구름 AI 자연어처리 과정 12기
2024.03~2025.03 고려대학교 NLP&AI lab 인턴
2025.03~2027.02 고려대학교 NLP&AI 석사과정 (지도교수 : 임희석)
2025.10~ 아는노무사 AI 엔지니어 테크 리드

Publications

1저자

- MIRAGE: A Metric-Intensive Benchmark for Retrieval-Augmented Generation Evaluation**
C. Park, H. Moon, H. Lim, *NAACL Findings*, 2025
- Can Small Open-Source Language Models With RAG Match GPT-4 Performance in Breast Cancer Clinical Decision Support?**
C. Park, I.H. Park, M. Kim, Y. Jang, H. Lim, Y. Hur. *JCO Clinical Cancer Informatics*, 2026
- Funnel-of-Thoughts: Efficient Test-Time Scaling via Early Voting and Rollout Pruning**
C. Park, S. Han, J. Yoon, S. Hong, H. Lim. *ArXiv*, 2026
- AgentHop: A Diagnostic Benchmark for Agentic Multi-Hop Scientific Question Answering**
C. Park, J. Yoon, S. Han, H. Moon, H. Lim. *NeurIPS E&D*, 2026

외 국제 학회 2편, 저널 1편, 테크 리포트 1편, 워크숍 1편, 국내 학회 3편, 아카이빙 2편 참여

MIRAGE: A Metric-Intensive Benchmark for Retrieval-Augmented Generation Evaluation

Noise Vulnerability

Query : When does the adventures of kid danger come out?
Answer : [January 19, 2018]
Doc_source : The Adventures of Kid Danger

Noise Span : The Adventures of Kid Danger is an American animated comedy television series created by Dan Schneider that aired on Nickelodeon from **January 15 to June 14, 2018.**

Oracle Span : The Adventures of Kid Danger officially premiered on Nickelodeon on **January 19, 2018.**

Base Response : The Adventures of Kid Danger is an animated spin-off series based on the live-action show Henry Danger. It premiered on Nickelodeon on **January 15, 2018.**

Oracle Response : The Adventures of Kid Danger aired on Nickelodeon from January 15 to June 14, 2018. It officially premiered on Nickelodeon on **January 19, 2018.**

Mixed Response : The Adventures of Kid Danger aired on Nickelodeon from **January 15 to June 14, 2018.**

Context Insensitivity

Query : What age group made up the highest percentage of the population?
Answer : [40 to 49]
Doc_source : Cunter

Oracle Span : Of the adult population, twenty-nine people or **14.6% of the population are between 20 and 29** years old. Twenty-eight people or 14.1% are 30 to 39, thirty-six people or **18.2% are 40 to 49**, and thirty-one people or 15.7% are 50 to 59.

Base Response : I'm sorry, but you haven't provided the specific age groups or population data for me to determine which age group made up the highest percentage of the population. Could you please provide more details so I can assist you better?

Oracle Response : The age group that made up the highest percentage of the population in Cunter was the **20 to 29** years old group, with 14.6% of the population falling within that age range.

Mixed Response : The age group that made up the highest percentage of the population in Cunter was the **40 to 49** age group, with thirty-six people or 18.2% of the population falling into that category.

Context Acceptability

Query : Who is the father of Sune Sik?
Answer : [Sverker I of Sweden]
Doc_source : Sune Sik

Oracle Span : Sune Sik, (born c. 1154), was allegedly a Swedish prince. According to Olaus Petri, he would have been a younger son of King **Sverker I of Sweden** and father of Ingrid Ylva.

Base Response : The father of Sune Sik is **Kim Sik.**

Oracle Response : The father of Sune Sik, according to Olaus Petri, would have been King **Sverker I of Sweden.**

Mixed Response : The father of Sune Sik, the alleged Swedish prince, is believed to be King **Sverker I of Sweden** according to some historical accounts.

Context Misinterpretation

Query : If the seaside resort in Victoria, Australia had retained its original name, what would Torquay be known as today?
Answer : [Spring Creek]
Doc_source : Torquay, Victoria

Oracle Span : From the 1860s, picnickers began to frequent the location, which was originally known as **Spring Creek**, after the watercourse along its south-western edge, but it was named **Puebla** in the 1882 Victorian Municipal Directory.

Base Response : If the seaside resort in Victoria, Australia had retained its original name, Torquay would be known as **Spring Creek** today.

Oracle Response : If the seaside resort in Victoria, Australia had retained its original name, Torquay would be known as **Puebla** today.

Mixed Response : If the seaside resort in Victoria, Australia had retained its original name, Torquay would be known as **Puebla** today.

문제의식

RAG가 틀렸을 때, 검색이 잘못된 문서를 준 것인지 생성 모델이 근거를 못 쓴 것인지 최종 정답률 (accuracy) 하나로는 구분할 수 없음 → 어디를 고쳐야 할지 알 수 없음

방법

Base 검색 없이 LLM 단독 / Oracle 정답 문서만 제공 / Mixed Top-5(정답 포함)

	Base	Oracle	Mixed
Noise Vulnerability	-	O	X
Context Acceptability	-	O	O
Context Insensitivity	X	X	-
Context Misinterpretation	O	X	-


데이터

공개 벤치마크 5종 → 위키피디아 검색 풀 구축, LLM 필터링 + 사람 검수
질의 7,560 · 검색 문서 37,800 — 로컬에서 돌릴 수 있는 경량 규모

결과 · 의의

NAACL 2025 Findings 게재 · 국내 특허 출원 · HuggingFace 누적 다운로드 1,700+
같은 방법론을 2편의 후속 연구 논문으로 확장

Can Small Open-Source Language Models With RAG Match GPT-4 Performance in Breast Cancer Clinical Decision Support?



문제의식

의료 LLM은 객관식·단답형 벤치마크로 평가되지만, 실제 진료는 빠르게 바뀌는 가이드라인에 근거한 장문 답변을 요구 → 벤치마크 성능이 현장 유용성으로 이어지는가?

방법

- 고려대 구로병원 종양내과 협업 과제
- ASCO 유방암 가이드라인 1,356건 수집·청킹
- SentenceTransformers + FAISS 검색
- 임상의가 실제 작성한 98개의 쿼리로 평가 수행
- 6개 모델 (GPT-4 · GPT-3.5 · Qwen2.5 · Llama3-8B · Meerkat · OpenBioLLM)
- RAG 유무에 따른 총 12개 생성 시나리오
- 설정 간 Win/Loss 비교 2,156회 × 12 (LLM-as-a-judge)


결과

- 소형 오픈소스 + RAG가 GPT-4에 근접한 결과 달성
- 의료 특화 모델(Meerkat · OpenBioLLM)이 12개 설정 중 최하위 4개

의의

벤치마크 점수와 현장 유용성이 같은 방향을 가리키지 않음을 수치로 확인
또한 LLM의 지식 수준이 최종 생성 품질과 반드시 비례하지 않음을 확인

Funnel-of-Thoughts: Efficient Test-Time Scaling via Early Voting and Rollout Pruning



문제의식

추론 모델의 다수결(Self-Consistency@32)은 정확하지만 생성 비용이 32배
기존 절감법은 보상 모델 학습이나 로짓 접근이 필요 → 추가 학습·모델 권한 전제

착안

115,200 건의 추론 모델 추론 과정을 분석하여 실패한 롤아웃은 망설임 표현 밀도가 높고,
성공한 롤아웃은 조기에 수렴함을 관찰.

방법

Early Voting : 빠르게 결론을 낸 응답을 최종 정답 집계에 활용
Rollout Pruning : 비생산적인 추론 경로를 일정 비율로 가지치기함


결과

Attention 연산량(FLOPs) 56% 감소, 총 소요 시간 37.6% 단축하면서 SC@32 정확도 달성
재학습·보상 모델·로짓 접근 없이 도메인 및 모델 전이가 가능한 프루닝 방법론 제안

현황

arXiv 공개 · 국내 특허 출원 (다중 샘플 추론 가속 방법)

AgentHop: A Diagnostic Benchmark for Agentic Multi-Hop Scientific Question Answering



문제의식

에이전트가 다중홉 과학 질문에 틀렸을 때, 검색 · 합성 · 도구 사용 · 자원 관리 중 어디서 실패했는지 정답률 (accuracy) 하나로는 알 수 없음

데이터 구축 과정

8단계에 걸친 생성 파이프라인 설계

- ① 9개 CS 학회로부터 시드 논문 953편 수집
 - ② 인용 체인 17,983개 (깊이 1-2) 생성
 - ③ 근거 기반 Q/A 1,651건 생성
 - ④ MCQ 문항 구성
 - ⑤ 모델 앙상블 기반 필터링 (-502)
 - ⑥ 구조 무결성 검사 (-71)
 - ⑦ 전문가 검수 (-35)
 - ⑧ 최종 후처리 작업 (-32)
- 최종 1,011건의 벤치마크 구성

진단 4축

1. Search – recall 기반 에이전틱 서치 능력 측정
2. Synthesis – 근거를 답으로 전환한 비율
3. Tool-use – 툰당 도구 호출 및 패턴 분석
4. Resource 토큰·턴·예산 초과 비율 추적

결과 · 현황

1. 검색을 잘하는 모델 (Opus 4.6)과 '응답 생성을 잘하는 모델 (Gemini-3 Pro)'이 다름
2. 에이전트 학습이 본격적으로 이루어지기 전 세대의 모델 (Qwen3)은 동일 크기라도 세대가 거듭하며 성능이 일관되게 상승함 (Qwen 3.5)을 확인


아는노무사: 법률 RAG 기반 HR 업무 자동화를 위한 SaaS 에이전트 설계 및 개발

LangGraph 기반 단일 State 누적 구조

1세대 · 2025.11

5

구성요소




단일 모델 Orchestrator

2세대 · 2026.03

9

구성요소




Planner, Executor, Composer 3단 구조

3세대 · 2026.05 → 현재

12

구성요소



역할 · 규모

- 4인 팀(AI 2 · 풀스택 1 · 현직 노무사 1)의 AI 파트 테크 리드
- RAG 파이프라인 구축** : 법령·판례 등 10종의 공개 데이터, 웹 검색 및 내부 검수 자료 등으로 노무 · 인사 특화 검색폴 구축
- 챗 에이전트 파이프라인 구축** : 단일 엔트리포인트로 법률 상담, 검토, 문서 생성 및 수정 기능 구현

세 번의 에이전트 구조 설계

- LangGraph 기반 단일 state 관리 구조 : 턴별 **state 누적 및 경직된 구조**의 한계 식별
- 단일 대형 모델 오케스트레이터 : 기능이 추가됨에 따라 **과도한 비용 누적** 발생
- Planner (구조화 계획) → Executor (병렬 실행) → Composer (생성)의 3단 구조
 - 전체 단계의 **병렬화 및 직렬화**로 TTFT 단축
 - 구조화 단계와 생성을 분리하여 **비용** 효율을 높이고 **품질** 개선
 - 구조 개선 후 첫 토큰 생성 시간을 2분 30초에서 20~30초로 대폭 단축

인프라

자체 서버를 통한 임베딩 서비스 배포
AWS S3와 에이전트의 연동을 통한 컨텍스트 감축 및 효율화
LangTrace 기반 비용 추적 진행
내부 품질 평가용 벤치마크 구축 및 디버깅 포탈 운영으로 지속적 품질 관리

서비스 현황

7월 한달 간 진행한 서비스 베타 공개에서 1,100명 이상의 사용자 방문 집계
현재 PoC 검증 후 서비스 배포 준비 중